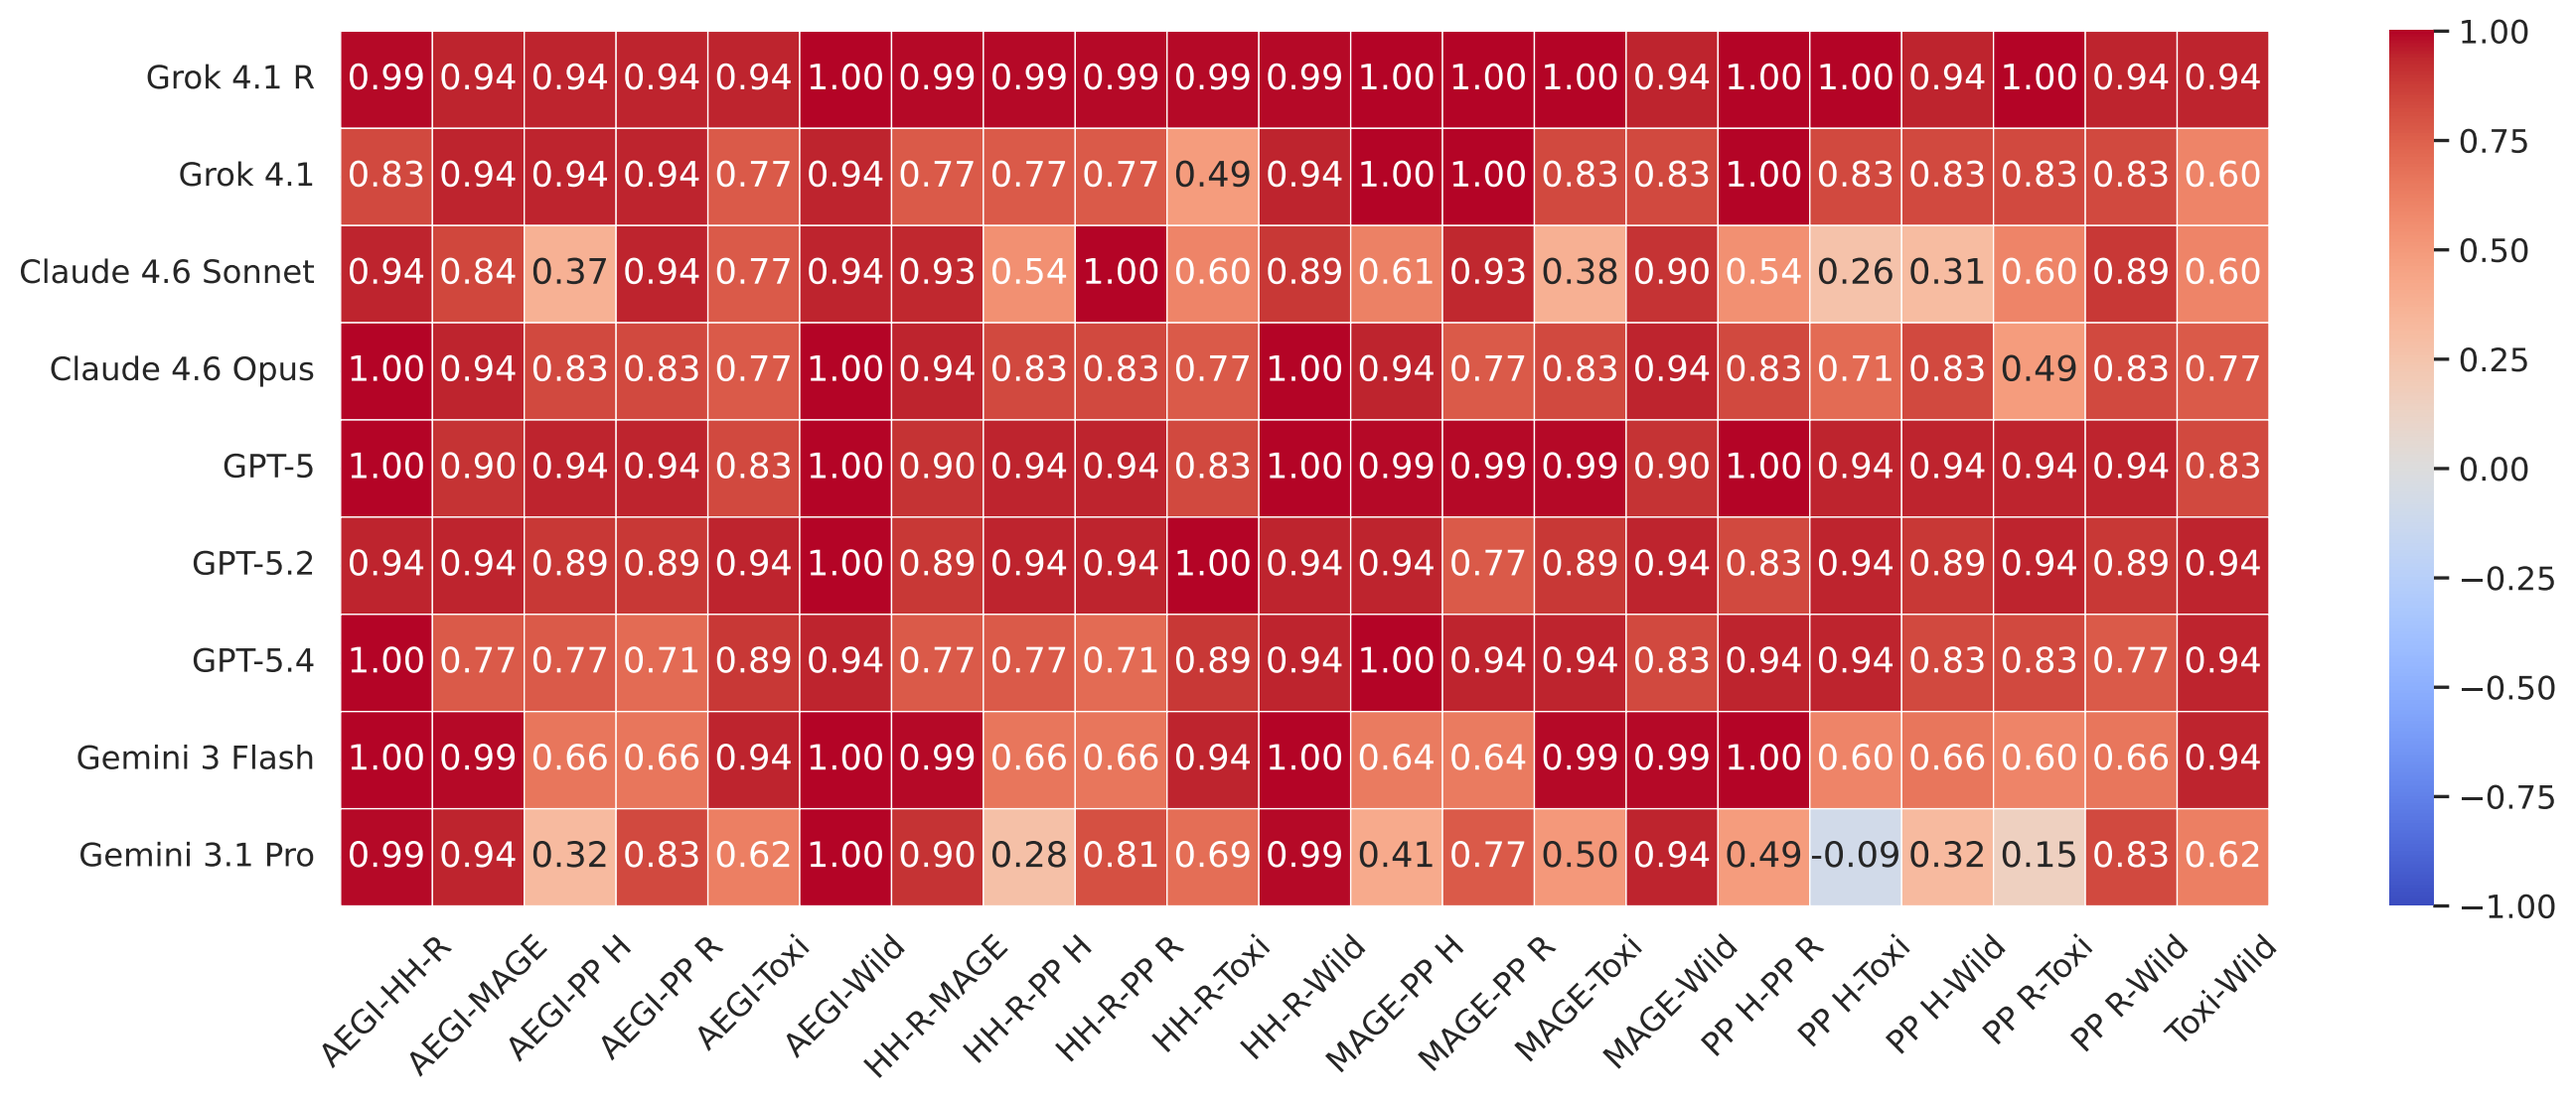
Grok 4.1 R 0.99 0.94 0.94 0.94 0.94 1.00 0.99 0.99 0.99 0.99 0.99 1.00 1.00 1.00 0.94 1.00 1.00 0.94 1.00 0.94 0.94
Grok 4.1 0.83 0.94 0.94 0.94 0.77 0.94 0.77 0.77 0.77 0.49 0.94 1.00 1.00 0.83 0.83 1.00 0.83 0.83 0.83 0.83 0.60
Claude 4.6 Sonnet 0.94 0.84 0.37 0.94 0.77 0.94 0.93 0.54 1.00 0.60 0.89 0.61 0.93 0.38 0.90 0.54 0.26 0.31 0.60 0.89 0.60
Claude 4.6 Opus 1.00 0.94 0.83 0.83 0.77 1.00 0.94 0.83 0.83 0.77 1.00 0.94 0.77 0.83 0.94 0.83 0.71 0.83 0.49 0.83 0.77
GPT-5 1.00 0.90 0.94 0.94 0.83 1.00 0.90 0.94 0.94 0.83 1.00 0.99 0.99 0.99 0.90 1.00 0.94 0.94 0.94 0.94 0.83
GPT-5.2 0.94 0.94 0.89 0.89 0.94 1.00 0.89 0.94 0.94 1.00 0.94 0.94 0.77 0.89 0.94 0.83 0.94 0.89 0.94 0.89 0.94
GPT-5.4 1.00 0.77 0.77 0.71 0.89 0.94 0.77 0.77 0.71 0.89 0.94 1.00 0.94 0.94 0.83 0.94 0.94 0.83 0.83 0.77 0.94
Gemini 3 Flash 1.00 0.99 0.66 0.66 0.94 1.00 0.99 0.66 0.66 0.94 1.00 0.64 0.64 0.99 0.99 1.00 0.60 0.66 0.60 0.66 0.94
Gemini 3.1 Pro 0.99 0.94 0.32 0.83 0.62 1.00 0.90 0.28 0.81 0.69 0.99 0.41 0.77 0.50 0.94 0.49 -0.09 0.32 0.15 0.83 0.62
AEGI-HH-R
AEGI-MAGE
AEGI-PP H
AEGI-PP R
AEGI-Toxi
AEGI-Wild
HH-R-MAGE
HH-R-PP H
HH-R-PP R
HH-R-Toxi
HH-R-Wild
MAGE-PP H
MAGE-PP R
MAGE-Toxi
MAGE-Wild
PP H-PP R
PP H-Toxi
PP H-Wild
PP R-Toxi
PP R-Wild
Toxi-Wild
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00